

$N+1$ vektorwertige Nebenbedingungen $\Rightarrow N+1$ vektorwertige Lagrange-Multipl. $\Sigma_0, \dots, \Sigma_N$

\hookrightarrow Lagrange-Funktion:

$$\mathcal{L}(\underline{x}_{0:N}, \underline{a}_{0:N-1}, \underline{\Sigma}_{0:N}) = J + (\underline{c} - \underline{x}_0)^T \cdot \underline{\Sigma}_0 + \sum_{k=0}^{N-1} \underbrace{(\underline{h}_k(\underline{x}_k, \underline{a}_k) - \underline{x}_{k+1})^T \cdot \underline{\Sigma}_{k+1}}_{\stackrel{!}{=} \text{nx Ende NB}}$$

Def.: Hamilton-Funktion

$$H_k(\underline{x}_k, \underline{a}_k, \underline{\lambda}_{k+1}) = g_k(\underline{x}_k, \underline{a}_k) + \underline{h}_k(\underline{x}_k, \underline{a}_k)^T \cdot \underline{\lambda}_{k+1} \dots$$

$$\hookrightarrow \mathcal{L}(\underline{x}_{0:N}, \underline{a}_{0:N-1}, \underline{\Sigma}_{0:N}) = g_N(\underline{x}_N) + (\underline{c} - \underline{x}_0)^T \underline{\Sigma}_0 + \sum_{k=0}^{N-1} (\underline{h}_k - \underline{x}_{k+1}^T \cdot \underline{\lambda}_{k+1})$$

Lösung des Optimierungsproblems

- Ableitung bzgl. \underline{x}_N :

$$\frac{\partial \mathcal{L}}{\partial \underline{x}_N} = \frac{\partial}{\partial \underline{x}_N} g_N(\underline{x}_N) - \underline{\Sigma}_N$$

$$\frac{\partial \mathcal{L}}{\partial \underline{x}_n} = \frac{\partial}{\partial \underline{x}_n} H_k - \underline{\lambda}_k = \underbrace{\nabla_{\underline{x}_k} g_k(\underline{x}_k, \underline{a}_k)}_{= g_k^x} + \underbrace{(\nabla_{\underline{x}_k}^* \underline{h}_k(\underline{x}_k, \underline{a}_k))^T}_{= h_k^x} \cdot \underline{\lambda}_{k+1} - \underline{\lambda}_k$$

mit $\frac{\partial \mathcal{L}}{\partial \underline{x}_k} = 0$ folgt:

$$\underline{\Sigma}_N = g_N^x(\underline{x}_N)$$

$$\underline{\lambda}_k = g_k^x(\underline{x}_k, \underline{a}_k) + h_k^x(\underline{x}_k, \underline{a}_k)^T \cdot \underline{\lambda}_{k+1}$$

Rückwärtsrelation
 $k=0, \dots, N-1$

\hookrightarrow Rückwärtsrelation für $\underline{\lambda}_k$

- Ableitung bzgl. \underline{a}_k :

$$\frac{\partial \mathcal{L}}{\partial \underline{a}_k} = \nabla_{\underline{a}_k} H_k(\underline{x}_k, \underline{a}_k, \underline{\lambda}_{k+1}) = \underbrace{\nabla_{\underline{a}_k} g_k(\underline{x}_k, \underline{a}_k)}_{= g_k^a} + \underbrace{(\nabla_{\underline{a}_k}^* \underline{h}_k(\underline{x}_k, \underline{a}_k))^T}_{= h_k^a} \cdot \underline{\lambda}_{k+1}$$

$\stackrel{!}{=} 0$

\hookrightarrow Notwendige Bedingung für eine Minimierung von H_k bzgl. \underline{a}_k

Ableitung bzgl. $\underline{\Sigma}_k$:

$$\frac{\partial \mathcal{L}}{\partial \underline{\Sigma}_0} = (\underline{c} - \underline{x}_0)^T \stackrel{!}{=} 0$$

$$\frac{\partial \mathcal{L}}{\partial \underline{\Sigma}_k} = \frac{\partial}{\partial \underline{\Sigma}_k} H_k - \underline{x}_k = h_{k-1}(\underline{x}_{k-1}, \dots)$$

Erklärung der Optimierung

Insgesamt: Notwendige Bedingungen an die Optimierung sind

Pontryagin'scher
Minimum-Prinzip

$$x_{k+1} = h_k(x_k, a_k)$$

$$\Delta_k = g_k^x(x_k, a_k) + h_k^x(x_k, a_k)^T \cdot \Delta_{k+1}$$

$$0 = \nabla_{a_k} H_k(x_k, a_k, \Delta_{k+1}) \quad (a_k = \arg \min_{a_k} H_k(x_k, a_k, \Delta_{k+1}))$$

für $k=0, \dots, N-1$ mit $\Delta_N = g_N^x(x_N)$ und x_0 fest.

Vorteil des Pontryagin'schen Minimum-Prinzip:

⊕ i.A. einfacher zu lösen als DP, da für einen Startzustand x_0

⊙ wie DP i.A. nicht gelöst werden kann, aber liefert effiziente Vorgehensweise zur Lösung des Problems von $J(x_{0:N}, a_{0:N-1})$ bzgl. $a_{0:N-1}$

Satz: Gegeben sei der Plan $a_{0:N-1}$. Co-state seien x_k, Δ_k durch

$$x_{k+1} = h_k(x_k, a_k)$$

$$\Delta_k = g_k^x(x_k, a_k) + h_k^x(x_k, a_k)^T \cdot \Delta_{k+1}$$

definiert mit x_0 gegeben und $\Delta_N = g_N^x(x_N)$. ~~x_N ist fest~~

Dann gilt für den Gradienten

$$\nabla_{a_k} J(x_{0:N}, a_{0:N-1}) = \nabla_{a_k} H_k(x_k, a_k, \Delta_{k+1})$$

$$J_0 + J_1 + \dots + J_{N-1} + J_N$$

Beweis

- Definiere Kostenfunktion für $k=0, \dots, N-1$

$$J_k(x_k, a_k) = g_k(x_k, a_k) + J_{k+1}(x_{k+1}, a_{k+1}, a_{k+2}, \dots)$$

- Ableitung bzgl. a_k :

$$\frac{\partial J_k}{\partial a_k} = g_k^a(x_k, a_k) + \frac{\partial J_{k+1}}{\partial a_k}$$

$$J_{k+1}(h_k(x_k, a_k), x_{k+2}, a_{k+2}, \dots)$$

$$\begin{aligned} &= \frac{\partial}{\partial a_k} \text{ beeinflusst } J_{k+1} \text{ lediglich durch } x_{k+1} = h_k(x_k, a_k) \\ &= g_k^a(x_k, a_k) + h_k^a(x_k, a_k)^T \cdot \nabla_{x_{k+1}} J_{k+1} \end{aligned}$$

Behauptung: $\Delta_k = \nabla_{x_k} J_k$:

• für $k=N$ gilt $\nabla_{x_N} J_N = g_N^x(x_N) = \Delta_N$

• für $k < N$ gilt $\nabla_{x_k} J_k = g_k^x(x_k, a_k) + h_k^x(x_k, a_k)^T \cdot \nabla_{x_{k+1}} J_{k+1}$

$$= \Delta h$$

$$\hookrightarrow \text{Gradient } \nabla_{\mathbf{h}_k} J_k = \mathbf{g}_k^a + \left(\frac{\partial}{\partial \mathbf{h}_k} \right)^T \cdot \mathbf{x}_{k+1} = \nabla_{\mathbf{h}_k} H_k \quad (*)$$

Nur notw. Bedingung!

Bezug zur dynamischen Programmierung (DP):

$$- DP: J_k(\mathbf{x}_k) = \min_{\mathbf{a}_k} \{ g_k(\mathbf{x}_k, \mathbf{a}_k) + J_{k+1}(\mathbf{h}_k(\mathbf{x}_k, \mathbf{a}_k)) \}$$

$$\hookrightarrow \frac{\partial}{\partial \mathbf{x}_k} (g_k + J_{k+1}) = \mathbf{g}_k^a(\mathbf{x}_k, \mathbf{a}_k) + \left(\frac{\partial}{\partial \mathbf{h}_k}(\mathbf{x}_k, \mathbf{a}_k) \right)^T \cdot \nabla_{\mathbf{x}_{k+1}} J_{k+1} \stackrel{!}{=} \mathbf{0}$$

- Vergleich mit (*):

$$\frac{\partial}{\partial \mathbf{a}_k} H_k = \mathbf{g}_k^a(\mathbf{x}_k, \mathbf{a}_k) + \left(\frac{\partial}{\partial \mathbf{h}_k}(\mathbf{x}_k, \mathbf{a}_k) \right)^T \cdot \mathbf{x}_{k+1} \stackrel{!}{=} \mathbf{0}$$

\hookrightarrow Lagrange-Mult. entsprechen dem Gradienten der Wertfunktion bzgl. \mathbf{x}_k

AMM

"Projektivierungsvollzugsproblem"

a) Ableitung bzgl. \mathbf{x}_k

$$\mathbf{g}_k^x = \frac{\partial}{\partial \mathbf{x}_k} (Q_k(\mathbf{x}_k - \hat{\mathbf{x}}_k)^2 + R_k \mathbf{a}_k^2) = 2 \cdot Q_k (\mathbf{x}_k - \hat{\mathbf{x}}_k)$$

$$\mathbf{g}_k^x = \frac{\partial}{\partial \mathbf{x}_k} Q_p(\mathbf{x}_p - \hat{\mathbf{x}}_p)^2 = 2 \cdot Q_p \cdot (\mathbf{x}_p - \hat{\mathbf{x}}_p)$$

$$\mathbf{h}_k^x = \frac{\partial}{\partial \mathbf{x}_k} (A_k \cdot \mathbf{x}_k + B_k \cdot \mathbf{a}_k) = A_k$$

Ableitung bzgl. \mathbf{a}_k :

$$\mathbf{g}_k^a = \frac{\partial}{\partial \mathbf{a}_k} (Q_k(\mathbf{x}_k - \hat{\mathbf{x}}_k)^2 + R_k \mathbf{a}_k^2) = 2 R_k \cdot \mathbf{a}_k$$

$$\mathbf{h}_k^a = \mathbf{B}_k$$

Beobachtung: Lineares Zustandsraummodell, quadratische Kosten

$\hookrightarrow H_k$ ist konvex bzgl. \mathbf{a}_k (für festes \mathbf{x}_k , \mathbf{h}_{k+1})

\hookrightarrow Notw. Bedingung ist auch hinreichend

\hookrightarrow Gradientenstieg liefert globales Minimum (optimale Lösung)

b) Algorithmus:

1. wähle $\mathbf{a}_0, \mathbf{p}_{0-1}$ beliebig (bel. Plan)

2. Bestimme $\mathbf{x}_{k,0-1}$ (Zustandfolgezielwerte) durch Lösen des Zustandsraummodells

3. Gebe die Lagrange-Multiplikatoren $\lambda_{1,k}$ und $\lambda_{2,k}$ an.
4. $a_0, v_0 \leftarrow$ Anfang in neg. Richtung d. Einheitsvektors.
5. Zurück zu 2. solange bis a_0, v_0 nicht konvergiert

Spezialfall: Lineare Planungsprobleme

Gegeben: Lineares Zustandsraummodell


Rauschen

$$x_{k+1} = A_k \cdot x_k + B_k \cdot u_k + w_k \quad \text{für } k=0, \dots, N-1$$

\uparrow Systemmatrix \nwarrow Eingangsmatrix

Systemmatrix

Beispiel: Fahrzeug auf Schiene



Bahn ist parabolische Funktion, x ist Parameter

$$x_k = \begin{bmatrix} x_k \\ v_k \end{bmatrix} \rightarrow \text{Pos} \\ \text{geschw.}$$

u_k - Geschw.-Änderung (Beschleunigung)

Mit Abtastintervall T :

$$A_k = \begin{bmatrix} 1 & T \\ 0 & 1 \end{bmatrix}$$

$$B_k = T \begin{bmatrix} \frac{1}{2} \cdot T \\ 1 \end{bmatrix}$$

$$x_{k+1} = x_k + T \cdot v_k$$

$$u_k \cdot B_k = \begin{bmatrix} \frac{1}{2} \cdot a_k \cdot T^2 \\ a_k \cdot T \end{bmatrix}$$

Zustands- und Abtastmenge: $x \in \mathbb{R}^{n \times 1}$, $A_k \in \mathbb{R}^{n \times n}$

Rauschen w_k :

- mittelwertfrei, d.h. $E\{w_k\} = 0$
- unabh. von x_k, u_k und w_i mit $i \neq k$
- charakterisiert durch Dichtefunktion $f_{w_k}(w_k)$

Ziel: Überführung von Initialzustand $x_0 \rightarrow \tilde{x} = [0, \dots, 0]^T$

durch Minimierung der quadratischen Kostenfunktion

$$E \left\{ x_0^T Q_0 x_0 + \sum_{k=0}^{N-1} (x_k^T Q_k x_k + u_k^T R_k u_k) \right\}$$

\nwarrow Symmetrisch, pos. definit

Bestimmung der opt. Strategie

• DP: $J_N(x_N) = \underline{x}_N^T \cdot Q_N \underline{x}_N$

$$J_h(x_h) = \min_{\underline{u}_h} \{ \underline{x}_h^T Q_h \underline{x}_h + \underline{a}_h^T R_h \underline{a}_h + E \{ J_{h+1}(x_{h+1}) | \underline{x}_{h+1}, \underline{a}_h \} \}$$

for $h=0, \dots, N-1$

• Betrachte Erwartungswert:

$$E \{ J_{h+1}(x_{h+1}) | \underline{x}_{h+1}, \underline{a}_h \}$$

$$= \int \underline{x} J_{h+1}(\underline{x}_{h+1}) \cdot f(\underline{x}_{h+1} | \underline{x}_h, \underline{a}_h) d \underline{x}_{h+1}$$

$$= f_h^w(\underline{x}_{h+1} - A_h \underline{x}_h - B_h \underline{a}_h)$$

$$= \int_0 \delta(\underline{x}_{h+1} - (A_h \underline{x}_h + B_h \underline{a}_h + \underline{w}_h)) \cdot f_h^w(\underline{w}_h) d \underline{w}_h$$

$$= \int_0 J_{h+1}(A_h \underline{x}_h + B_h \underline{a}_h + \underline{w}_h) \cdot f_h^w(\underline{w}_h) d \underline{w}_h$$

Rausheben

$$= E_w \{ J_{h+1}(A_h \underline{x}_h + B_h \underline{a}_h + \underline{w}_h) | \underline{x}_h, \underline{a}_h \}$$

Induktionsannahme: Behauptung $J_{h+1}(x_{h+1}) = \underline{x}_{h+1}^T P_{h+1} \underline{x}_{h+1} + c_{h+1}$

mit P_{h+1} ... symmetrisch, pos.-semidefinit Matrix

c_{h+1} ... reelle Konstante

- Induktionsanfang: $h=N-1$

$$\Rightarrow P_N = Q_N \text{ und } c_N = 0$$

- Induktionsfortschritt: Behauptung gilt für $h+1$

- Induktionschluss:

$$J_h(x_h) = \min_{\underline{u}_h} \{ \underline{x}_h^T Q_h \underline{x}_h + \underline{a}_h^T R_h \underline{a}_h + E_w \{ (\underbrace{A_h \underline{x}_h + B_h \underline{a}_h}_{=0} + \underline{w}_h)^T P_{h+1} (\underbrace{A_h \underline{x}_h + B_h \underline{a}_h}_{=0} + \underline{w}_h) + c_{h+1} \} \}$$

$$= \underline{x}_h^T Q_h \underline{x}_h + \min_{\underline{a}_h} \{ \underline{a}_h^T R_h \underline{a}_h + \underbrace{\underline{a}_h^T B_h^T P_{h+1} B_h \underline{a}_h + 2 \cdot \underline{x}_h^T A_h^T P_{h+1} B_h \underline{a}_h}_{(*)} \}$$

$$+ \underline{x}_h^T A_h^T P_{h+1} A_h \underline{x}_h + E \{ \underline{w}_h^T P_{h+1} \underline{w}_h \} + c_{h+1} \quad (**)$$

- Minimierung von $(*) \rightarrow$ Ableiten bzgl. \underline{a}_h und zu Null setzen

$$- \frac{\partial x^T A x}{\partial x} = 2 A x \quad \text{da } A \text{ symmetrisch}$$

$$- \frac{\partial a^T x}{\partial x} = \frac{\partial x^T a}{\partial x} = a$$

Symmetrische Matrix per Definition

$$L) (*)' = \cancel{2 R_u} \underline{a_u} + \cancel{2 P_u^T \cdot P_{uu} \cdot B_u} \underline{a_u} + \cancel{2 P_u^T P_{uu}} \underline{a_u} \stackrel{!}{=} 0$$

$$\hookrightarrow (R_u + B_u^T P_{uu} B_u) \cdot \underline{a_u} = - B_u^T \cdot P_{uu} \cdot A_u \underline{x_u} \quad (\text{Lineares GLS bzgl. } \underline{a_u})$$

$$\hookrightarrow \underline{a_u}^* = - (R_u + B_u^T P_{uu} B_u)^{-1} \cdot B_u^T \cdot P_{uu} \cdot A_u \underline{x_u}$$

$$=: L_u \quad \text{"Verstärkungsmatrix"}$$

$$L) \text{ Opt. Strategie } \Pi_u^*(\underline{x_u}) = L_u \cdot \underline{x_u} \quad \text{↗ Linear in } \underline{x_u}$$

Linearer quadratischer Regulator (LQR)

Zustands-
summand

Kosten

wird zuerst in der
Regelungstechnik entdeckt- Abschluss der Induktion: Einsetzen von $\underline{a_u}^*$ in $(*)$ liefert

$$J_u(\underline{x_u}) = \underline{x_u}^T P_u \cdot \underline{x_u} + c_u$$

mit

$$P_u = A_u^T (P_{uu} - P_{uu} B_u (R_u + B_u^T P_{uu} B_u)^{-1} B_u^T P_{uu}) A_u + Q_u$$

$$c_u = E \{ \underline{w}_u^T \cdot P_{uu} \cdot \underline{w}_u \} + c_{uu}$$

$$\hookrightarrow \text{Rückwärtsrekursion für } P_u \text{ mit } P_N = Q_N$$

↑
Zeitdiskrete Riccati-GleichungInterpretation der Kostenfunktion

$$\underline{x}_N^T \cdot Q_N \cdot \underline{x}_N + \sum_{k=0}^{N-1} \underline{x}_k^T Q_k \underline{x}_k$$

zustandsabhängige Kosten

Bewerte Abschätzung von Ziel

$$\underline{\hat{x}} = [0 \dots 0]^T$$

Ist Q_k diagonal mit $q_{ii} \geq 0$

$$\underline{x}_k^T Q_k \underline{x}_k = \sum_{i=1}^n q_{ii} \cdot \underline{x}_{ki}^2$$

Erwartung

quadr. Abschätzung

$$\sum_{k=0}^{N-1} \underline{a}_k^T R_k \underline{a}_k$$

aktionsabhängige Kosten

Bewerte aufgespeicherte "Energie" von $\underline{\hat{x}}$ zu erwartenIst Rückgangswahrscheinlichkeit mit $r_{ii} \geq 0$

$$\underline{a}_k^T R_k \underline{a}_k = \sum_{i=1}^n r_{ii} \cdot \underline{a}_{ki}^2$$

Ist $r_{ii} = 0$, so kann \underline{a}_{ki} sehr groß sein

kann nicht beobachtet werden

Große r_{ii} bedeuten die "Energie"↗ Abhängigkeit von der Verlauf von \underline{x}_k

- Ist dabei $q_{ii} = 0$, so wird die Abschätzung in \underline{x}_{ki} nicht berücksichtigt
- Große q_{ii} betreffen das Verhalten

Unsere App für ein einfacheres Studium:

Ladet auf www.bloxxboard.com

Beispiel: $A_k = B_k = I$ und $R_k = r \cdot I$ $Q_k = q \cdot I$ für alle k mit $q, r \in \mathbb{R}^+$
 $-q \gg r$: $P_{N-1} = (Q_N - Q_N (Q_N + R_{N-1})^{-1} Q_N) + Q_{N-1} \approx Q_{N-1}$

$$\hookrightarrow P_k \approx Q_k \text{ für alle } k$$

$$\hookrightarrow L_k \approx -(Q_{k+1} + R_k)^{-1} Q_{k+1} \approx -I$$

$$\hookrightarrow a_k^* \approx -x_k$$

$$-r \gg q: P_{N-1} = (Q_N - Q_N (Q_N + R_{N-1})^{-1} Q_N) + Q_{N-1} \approx Q_N + Q_{N-1} = 2 \cdot q \cdot I$$

Überproport.
 starkes bestrafen
 der aufgewendeten
 Energie

$$\hookrightarrow P_k \approx (N-k+1) \cdot q \cdot I = (N-k+1) Q_k$$

$$\hookrightarrow L_k \approx -((N-k+1) \cdot Q_{k+1} + R_k)^{-1} \cdot Q_{k+1} \approx 0$$

$$\hookrightarrow a_k^* \approx 0 \Rightarrow \text{keine Zustandsänderung}$$

$$-q = r: L_k \hat{=} \text{goldener Schnitt}$$

Kritische Betrachtung:

- ⊕ geschlossenes berechenbares der ~~goldenen~~ opt. Strategie
- ⊖ viele Freiheitsgrade, z.B. Q_k besitzt $\frac{1}{2} n \times (n+1)$ freie Parameter (und P -Matrix, für jeden Zeitschritt k)
- ⊖ physikalische Zurechnung schwer/gut nicht herstellbar
 \hookrightarrow iterativer Prozess zur Bestimmung von Q_k, P_k (vorstellbar falls Simulation des Systems vorhanden)

A12 wählt: $Q_k = q_k \cdot I$ mit $q_k = 10$
 $Q_N = q_N \cdot I$ mit $q_N = 20$
 $R_k = r_k \cdot I$ mit $r_k = 1$

- a) \bullet Konnung der Bahn nicht berücksichtigt
 art.
 \bullet Beschleunigung nicht realisierbar
 \bullet Geschwindigkeit evtl. nicht realisierbar

Sicherheitäquivalenz (engl. certainty equivalence)

- \bullet Beobachtung: Verteilungsmatrix L_k und Strategie π_k^* sind unabhängig vom Realisieren ω_k

- \bullet Grund Lin Modell und quadratische Kostenfunktion (und weniger unabhängiger Parameter)

\Rightarrow Dasselbe optimale Strategie ergibt sich bei Betrachtung des Kostenfunktionswertes.
 Zustandsraummodell $x_{k+1} = A_k \cdot x_k + B_k \cdot u_k$ bei welchem das Kosten J durch lassen

Unsere App für ein einfacheres Studium: BW & WLB = 0 excited ist.
 Hol sie dir jetzt auf www.bloxxboard.com