

A1.3 Tracking

a) Optimierte Strategie $\pi_k^*(x_k) = L_k x_k + G_k \underline{s}_k$ mit

$$L_k = -(R_k + B_k^T P_{k+1} B_k)^{-1} B_k^T P_{k+1} A_k$$

$$P_N = Q_N$$

$$P_k = A_k^T (P_{k+1} - P_{k+1} B_k (R_k + B_k^T P_{k+1} B_k)^{-1} B_k^T P_{k+1}) A_k + Q_k$$

$$G_k = (R_k + B_k^T P_{k+1} B_k)^{-1} B_k^T$$

$$\underline{s}_N = Q_N \cdot \underline{x}_N \leftarrow \text{keine Rauschen fließt ein!}$$

$$\underline{s}_k = Q_N \cdot \underline{x}_N + (A_k + L_k B_k) \underline{s}_N$$

Betrachtung: $G_k, \underline{s}_k, \underline{s}_N$ sind unabhängig vom Rauschen $w_k \Rightarrow$ Schätzungsproblem


Planning bei Messunsicherheit

Bisher: Zustand direkt zugänglich \rightarrow zu Zeitpunkt k exakt bekannt

Jetzt: Agent erhält nur Beobachtungen / Messungen des Zustands:

Probleme:

- Rauschen im Messdaten
- indirekte Messung
(Position gewusst, Abstand gemessen)
- niedrigdimensional



\Rightarrow Partiell beobachtbares mathematisches Entscheidungsproblem (POMDP) zur Modellierung (engl. partially observable Markov decision process)

Definition: MDP mit folgenden Unterschieden:

3. Initialzustand $x_0 \in \mathcal{X}$ mit Verteilung $P(x_0)$
7. Beobachtung / Messung $z_k \in \mathcal{Z}$ gemäß der bedingten Verteilung

\uparrow
ML Ingenieurswissenschaften

$$z_k \sim P(\cdot | x_k, s_{k-1}) \quad (\text{Beobachtungswahrscheinlichkeit})$$

- Diskrete Beobachtungen \rightarrow bed. Wahrscheinlichkeit $f(z_k | x_k, s_{k-1}) = P(z_k = z_k | x_k, s_{k-1})$
- Kontinuierl. Beobachtungen \rightarrow bed. W. $f(z_k | x_k, s_{k-1}) = \frac{\partial P(z_k | x_k, s_{k-1})}{\partial z_k} \Big|_{z_k = z_k}$

}
klarendes
LQR

Beispiel: kont. Zustandsmodell

$$z_k = h_k(z_{k-1}, u_{k-1}, v_k)$$

Messwerte mit Dichte f_{v_k}

Wert von z_{k-1} aus ω_{k-1} , v_k und u_{k-1}

richtige Funktion $h_k: X \times A \times V \rightarrow Z$

z.B. Abstandsmessung zu Landmarke in 2.D

$$z_k = \sqrt{(x_k - x^{LM})^2 + (y_k - y^{LM})^2} + v_k$$

Position x_k Landmarke x^{LM}

- ① Allgemeine Rauschen
- ② Anwendung Distanz-S-Pkt möglich
(Ansetzen der Abstandsmessung)
- ③ Negative Messwerte in Abstandsmessung möglich

Beobachtungswelt

$$f(z_k | z_{k-1}, u_{k-1}) = \int_v \delta(z_k - h_k(z_{k-1}, u_{k-1}, v)) \cdot f_v(v) dv$$

Likelihood: $f(x|y)$
↑ y verkannt
bekannt

D. Aufgabe: Minimierung der erwarteten Kosten

$$J_{\Sigma_{0:N-1}}(\cdot) = E \{ g_N(z_N) + \sum_{n=0}^{N-1} g_n(z_n, \pi_n(\cdot)) \}$$

bzgl. der Strategie $\Sigma_{0:N-1} = (\pi_0, \dots, \pi_{N-1})$ mit $\pi_n(\cdot) = a_n \in A_n$.

Reformulierung als MDP

- Problem: keine vollständige Information über Zustand z_k
- Aber: Zugriff auf Beobachtungen
- Idee: Definition eines neuen Zustandes, welcher
 - direkt zugänglich ist
 - alle vorliegenden Informationen über z_k zum Zeitpunkt k enthält

\Rightarrow Informationsvektor / Zustand

ProPlan, 09.06.2015, 8.VL

$$\underline{I}_h = (\underline{x}_{01}, \dots, \underline{x}_{h+1} | \underline{a}_0, \dots, \underline{a}_{h-1}) \quad \text{für } h=1, 2, \dots, N$$

$$\underline{I}_0 = \underline{x}_0$$

$$\hookrightarrow \underline{I}_{h+1} = (\underline{I}_h, \underline{x}_{h+1} | \underline{a}_h) \quad \text{für } h=0, \dots, N-1$$

- Beschreibt zeitliche Entwicklung des Agenteen

- Mit $P(x_0)$ und I_h ist sämtliche Information gegeben, um zum Zeitpunkt h eine Planungsentscheidung zu treffen.

- korrespondierendes MDP: Informationsvektor-MDP

$$\hookrightarrow \text{DP: } J_N(I_N) = \mathbb{E}_{\underline{g}_N}(x_N) | I_N$$

$$J_N(I_h) = \min_{\underline{a}_h} \mathbb{E}_{x_{h+1}} g_h(x_h, \underline{a}_h) + J_{h+1}(I_{h+1}, \underline{x}_{h+1} | \underline{a}_h)$$

$$\text{für } h=0, 1, \dots, N-1$$

$$\hookrightarrow \text{Strategie } \underline{I}_h^*(I_h) = \underline{a}_h^*$$

Nachteile:

- Nur in Ausnahmefällen geschlossenlösbar (z.B. lineare Modelle)
- Zustand I_h wächst mit der Zeit

Beobachtung: Beobachtung der Verteilung von $x_{h+1}, \underline{x}_{h+1}$ erforderlich.

Hausende Statistiken (engl. sufficient statistics)

Ziel: Kompression, d.h. Darstellung von I_h mit geringerer Dimension

Definition:

Seien $S = \{z_1, \dots, z_n\}$ Stichproben (samples) einer ZV $z \sim P(z | \Theta)$ mit unbekanntem Parameter Θ . Eine Statistik ist eine Funktion $T(S) = t$, welche zwar von S , nicht aber von Θ abhängt.

Beispiel: S ist Stichprobe einer normalverteilten ZV z mit Dichte

$$f(z | \Theta) = \mathcal{N}(z | \mu, \sigma^2) = \frac{1}{\sqrt{2\pi}\sigma} \cdot \exp\left\{-\frac{(z-\mu)^2}{2\sigma^2}\right\}$$

$$\cdot \sum_{j=1}^n z_j^2 = T(S) \quad i \in \mathbb{N} \text{ ist eine Statistik}$$

$$\cdot \sum_{j=1}^n (z_j - \mu)^2 \text{ ist keine Statistik (weil es vom Parameter } \mu \text{ abhängt)}$$

Proplay, 03.06.2015, 8VL
Definition

Statistik $T(S) = t$ heißt hinterlegend für Θ , sofern keine weitere Statistik auf S ex., welche zusätzliche Informationen über Θ liefert.

↪ Ist $T(s) = t$ gegeben, dann liefert keine Kenntnis von s keine Bezeichnungen über Θ .

↪ s kann verworfen werden
↪ Kompromiss, wenn $\dim(t) < \dim(s)$

Beispiel: Der Stichprobenmittelwert $\bar{z} = \frac{1}{n} \sum_{j=1}^n z_j$

Von n unabhängige z_j einer normalverteilten RV z mit Dichte $N(z|\mu, \sigma)$ ist eine hinterlegende Statistik für μ .

Beispiel: Hinterlegende Statistik für Poisson ist die Identität $I_n(I_n) = I_n$

Bedingte Zustandswertung.

Satz: Die bed. Verteilung $P(x_{n+1}|I_n)$ des Zustands x_n stellt eine hinterlegende Statistik dar.

Lemma: Die bed. Verteilung $P(x_n|I_n)$ lässt sich mittels $P(x_{n+1}|I_n) = f(x_{n+1}) / f(x_n)$

$$P(x_{n+1}|I_{n+1}) = \phi_n(P(x_n|I_n), g_n, z_{n+1})$$

reziproqu aufschreiben

Beweis für X, A, Z kontinuierlich

• Gegeben: Dichte $f(x_n|I_n)$

• Prädiktionschritt: $n \rightarrow n+1$ Unabhängigkeit von I_n

$$f(x_{n+1}|I_n, a_n) = \int_x f(x_{n+1}|x_n, y_n) / f(x_n|I_n) d x_k$$

Chernoff-Holmogorov-Integration - im Intervall a_n Ausmaßnahme

• Filterschritt: Abbildung durch Beobachtung z_{n+1}

$$\begin{aligned} f(x_{n+1}|I_{n+1}) &= f(x_{n+1}|I_n, z_{n+1}) = \{\text{Def. bed. Dichtes}\} \\ &= \frac{f(x_{n+1}|x_n, a_n|I_n, z_{n+1})}{f(z_{n+1}|I_n, a_n)} \end{aligned}$$

Beobachtungsmodell

$$= f(z_{unl} | x_{unl}, I_{unl}) \cdot f(x_{unl} | I_{unl}, a_u)$$

$$f(z_{unl} | I_{unl}, a_u)$$

* f Beobachtung "Wheat ist unabhängig von x_u "

$$= f(z_{unl} | x_{unl}, a_u) \cdot f(x_{unl} | I_{unl}, a_u) = \textcircled{1}$$

$$f(z_{unl} | I_{unl}, a_u) = \textcircled{2}$$

$$\textcircled{1} = \int_Z f(z_{unl} | x_{unl}, a_u) \cdot f(x_{unl} | I_{unl}, a_u) d z_{unl}$$

\textcircled{1} = "Posteriorisierungskonstante"

\textcircled{2} = "predictive Dichte"

$\hookrightarrow \Phi_u$ = Produktion + Filterdicht = Bayes'scher Schätzer

Vorlesungen: Kalman-Fitter, HMM-Fitter, Partikel-Fitter, Monte-Carlo-Sampling, ...

Deweit (Satz): für X, A, z kontinuierlich

$$\text{z.B.: } J_h(I_h) = \bar{J}_h(P(x_h | I_h)) \text{ für geeignete } \bar{J}_h$$

I.A.: $h = N$

Zustandsverteilung steht hier

$$\bar{J}_N(I_N) = E_z g_N(x_N) | I_N = \int_Z g_N(x_N) \cdot \overline{f(x_N | I_N)} d x_N$$

$$= \bar{J}_N(P(x_N | I_N))$$

$$\text{I.V.: } J_{hu}(I_{hu}) = \bar{J}_{hu}(P(x_{hu} | I_{hu}))$$

$$\text{I.S.: } J_h(I_h) = \min_{g_h} \{ E_z \{ g_h(x_h, a_h) + \bar{J}_{hu}[\Phi_h(P(x_h | I_h), a_h, z_{hu})] | I_{hu} \} \}$$

$$= \min_{g_h} \{ E_z \{ g_h(x_h, a_h) \} + \underbrace{E_z \{ \bar{J}_{hu}[\dots] | I_{hu}, a_h \} \}}_{\text{Fkt. von } P(x_h | I_h)}$$

$$= \int_Z g_h f(x_h | I_h) d x_h$$

= Fkt. von $P(x_h | I_h)$

$$= \int_Z \bar{J}_h f(z_{hu} | I_{hu}, a_h) d z_{hu}$$

$$= \int_X f(z_{unl} | x_{unl}, a_u) \cdot f(x_{unl} | I_{unl}, a_u) d x_{unl}$$

Minimierung

= Funktion von $P(x_h | I_h)$

$$= \bar{J}_h(P(x_h | I_h))$$

$$\hookrightarrow \text{DP: } \bar{J}_h(P(x_h | I_h)) = E_x \{ g_h(x_h) | I_h \}$$

Zeigt $P(z_{hu} | I_h)$ her

Pro Plan, 03.06.2015, VL 8

$$\bar{J}_n(P(x_n|I_n)) = \max_{a_n} \left(E_{x_{n+1}} g_h(x_{n+1}) + \bar{J}_{n+1}(P(x_{n+1}|I_{n+1}), g_h \text{ bzw. } I_{n+1} \text{ an}) \right)$$

für $n=0, \dots, N-1$

Liefert optimale Strategie $I_{0:N-1}^*$ mit $I_n^*(P(x_n|I_n)) = a_n \in A_n$
 \Rightarrow z.B. Verfolgungs-MDP (engl. Pursuit-State MDP)

Folie 3
Folie 10

Planungsalgorithmen bestehen aus zwei Bestandteilen:

1. Schätzer: Berechnet $P(x_n|I_n)$ aus a_{n-1} und z_n

- Prädiktion: $P(x_{n+1}|I_{n-1}) \xrightarrow{a_{n-1}} P(x_n|I_{n-1}, a_{n-1})$

- Filterung: $P(x_n|a_{n-1}) \xrightarrow{z_n} P(x_n|I_n)$

2. Strategie: Berechnet a_n aus $P(x_n|I_n)$.

Liefert nur Theorie, praktisch selten direkt anwendbar

- Bayes'scher Schätzer i.d.R. nicht geschlossen lösbar berechenbar

- Prädiktionsintegral

- Produkt aus Beobachtungswahrscheinlichkeit und prädizierter Dichte

- Normalisierungskonstante kann $\int \text{Integral} \rightarrow$ kann praktisch sehr

- Aktion am besten Zustand x_{n+1} und Beobachtung z_{n+1}

↳ Zugehörigkeit zu einer oder mehreren Strategien nur für Implementierung

↳ Opt. Lösung des Schätz- und Planungsproblem sind verknüpft.


- Beobachtung: Dimension des Raums aller Verteilungen ist unendlich

Aber: In vielen Fällen lässt sich die Verteilung durch eine endliche Anzahl von Parametern beschreiben

Subst.: Ist $P(x_n|I_n) = g_n(T_n|I_n)$ für eine geeignete Funktion $g_n(\cdot)$, dann ist $T_n(I_n)$ eine hinreichende Statistik

Beispiel: $P(x_n|I_n)$ ist Normalverteilung \Rightarrow Mittelwert und Kovarianzmatrix sind konstant

ProPlan, 03.06.2015, § VL

A14) Maschinenwartung

a) Informationsvektor-MDP:

- Bestandsmenge $X = \{P, \bar{P}\}$, Aktionsmenge $A = \{C, S\}$, $Z = \{D, G\}$
Gute \uparrow \downarrow stop

• Init-Wkst:

$$f(r_0 = P) = \frac{2}{3} \quad f(r_0 = \bar{P}) = \frac{1}{3}$$

• Wegegewkst für $h=0,1$:

$$f(x_{h+1} = P | x_h = P, a_h = C) = \frac{2}{3} \quad f(\bar{P} | P, C) = \frac{1}{3}$$

$$f(P | \bar{P}, C) = 0$$

$$f(\bar{P} | \bar{P}, C) = 1$$

$$f(P | P, S) = \frac{2}{3}$$

$$f(\bar{P} | P, S) = \frac{1}{3}$$

$$f(P | \bar{P}, S) = \frac{2}{3}$$

$$f(\bar{P} | \bar{P}, S) = \frac{1}{3}$$

Beobachtungswkst für $h=0,1$:

$$f(z_h = G | r_h = P) = \frac{3}{4} \quad f(D | P) = \frac{1}{4}$$

$$f(G | \bar{P}) = \frac{1}{4} \quad f(D | \bar{P}) = \frac{3}{4}$$

Informationsvektoren für $h=0,1$:

$$I_0 = z_0, \quad I_1 = (z_0, r_1, a_0)$$

Gesucht: $\pi_0^*(I_0), \pi_1^*(I_1)$ DP:

$$J_2(I_2) = 0$$

$$\begin{aligned} J_h(I_h) &= \min \{ E_h[g(x_h, C)] + E_{h+1} \{ J_{h+1}(F_{h+1}, z_{h+1}) | I_h, C, \\ &\quad F_{h+1}, g(x_{h+1}, S) \} + \dots \} \\ &= \min \{ f(P | I_h) \cdot g(P, C) + f(\bar{P} | I_h) \cdot g(\bar{P}, C) + E_{h+1} \{ \dots \} \\ &\quad f(P | I_h) \cdot g(P, S) + f(\bar{P} | I_h) \cdot g(\bar{P}, S) + E_{h+1} \{ \dots \} \} \end{aligned}$$

for $h=0,1$

Not: $I_h = (z_h, r_h, a_h) \rightsquigarrow 8$ mögliche Informationsvektoren
 Erw.-Volumen Kosten für $a_h = C$: $\frac{2}{3} \cdot f(\bar{P} | I_h) \Rightarrow J_h(I_h) = \min \{ 2, \frac{2}{3} \cdot f(\bar{P} | I_h), 1 \}$

Erw.-Volumen Kosten für $a_h = S$: $\frac{1}{3} \cdot f(P | I_h) \Rightarrow J_h(I_h) = \min \{ 1, \frac{1}{3} \cdot f(P | I_h), 1 \}$

ProPlan, 03.06.2015, S. 12

p!

- Berechnung von $f(\bar{P} | I_1)$ für alle I_1 : Beobachtungs-Welt
 ↳ Allgemein: $f(x_1 | z_1, z_0, a_0) = \frac{f(z_1 | x_1) \cdot f(x_1 | z_0, a_0)}{\sum_{x_1} f(z_1 | x_1) \cdot f(x_1 | z_0, a_0)}$

(Filter-Schritt)

$$f(x_1 | z_0, a_0) = \sum_{x_0} f(x_1 | x_0, a_0) \cdot f(x_0 | z_0)$$

↑ Übergangsverlust

(Prediction)

$$f(x_0 | z_0) = \frac{f(z_0 | x_0) \cdot f(x_0)}{\sum_{z_0} f(z_0 | x_0) \cdot f(x_0)} \leftarrow \text{Lat.-Welt}$$

$$\qquad\qquad\qquad \leftarrow \text{Beobachtungs-Welt}$$

$$(1): I_1 = (G_1, G_1, S)$$

$$\begin{cases} 1. \text{ Filterdritt} \\ \end{cases} f(x_0 = P | G_1) = \frac{3/4 \cdot 2/3}{3/4 \cdot 3/3 + 1/4 \cdot 1/3} = \frac{6}{7}$$

$$f(x_0 = \bar{P} | G_1) = \frac{1/12}{7/12} = 1/7$$

$$f(x_1 = P | G_1, S) = 2/3 \cdot (f(x_0 = P | G_1) + f(x_0 = \bar{P} | G_1)) = 2/3$$

$$f(x_1 = \bar{P} | G_1, S) = 1/3$$

$$f(x_1 = \bar{P} | G_1, G_1, S) = \frac{2/4 \cdot 1/3}{2/4 \cdot 1/3 + 3/4 \cdot 2/3} = \frac{1/12}{1/12 + 1/2} = 1/7$$

$$\hookrightarrow J_1 | I_1 = \max(2 \cdot 1/7, 1/3 \cdot 2/7) \Rightarrow a_1^* = C$$

... (für alle restlichen 7 Informationszustände auch)

z_0	$\underline{z_1}$	a_0	J_1	π_1^*
A	G	S	2/7	C
G	B	S	1	S
G	B	S	1	S
G	G	C	5/7	C
G	B	C	22/23	C
G	B	C	1	S
G	B	C	1	S

Insges. Ist $\underline{z}_1 = B_1$, dann sollte $a_1 = S$ (Stop)
 $\underline{z}_1 = B_2$, dann " " $a_1 = C$ (Weiter betreiben)

ProPlan, 03.06.2015, 8.VL

$k=0$

(1) $I_0 = S_0 \rightarrow 2$ mögliche Informationsauctorien

$$I_0 = G$$

$$\hookrightarrow J_0(S_0) = \min\{2^{S_0}/2^8, 1^{S_0}/2^8\} = 2^{S_0}/2^8$$

$$\hookrightarrow \pi_0^*(S_0) = C$$

$$I_0 = B$$

$$\hookrightarrow J_0(B) = \min\{1^{B_0}/2^8, 1^{B_0}/2^8\} = 1^{B_0}/2^8$$

$$\hookrightarrow \pi_0^*(B) = S$$

↳ Insgesamt: Opt. Strategie mit $a=C$ zu wählen, wenn Information G loopt, und $a=S$.

b) Definere $f_1 := f(x_1 = \bar{P} | I_0)$

$$f_0 := f(x_0 = \bar{P} | I_0)$$

$$\hookrightarrow f_1 = \phi_0(f_0, a_0, z_1) = \begin{cases} 1/7 & , \text{ for } a_0 = S, z_1 = B \\ 3/15 & , \text{ for } a_0 = S, z_1 = B \\ \frac{1+2f_0}{7-4f_0} & , \text{ for } a_0 = C, z_1 = B \\ \frac{3+6f_0}{5+4f_0} & , \text{ for } a_0 = C, z_1 = B \end{cases}$$

• $k=1 \Rightarrow \bar{J}_1(f_1) = \min\{2 \cdot f_1, 1\}$

$$\hookrightarrow \pi_1^*(f_1) = \begin{cases} C & , \text{ for } f_1 \leq \frac{1}{2} \\ S & , \text{ sonst} \end{cases}$$

• $k=0$

$$\bar{J}_0(f_0) = \min\{2 \cdot f_0 + f(z_1 = G | f_0, C) \cdot \bar{J}_1(\phi_0(C, G)), \\ f(z_1 = B | f_0, C) \cdot \bar{J}_1(\phi_0(C, B))\},$$

$$1 + f(z_1 = G | f_0, S) \cdot \bar{J}_1(\phi_0(S, G)), \\ f(z_1 = B | f_0, S) \cdot \bar{J}_1(\phi_0(S, B))$$


$$= \min\{2 \cdot f_0 + \frac{7-4f_0}{12} \cdot \bar{J}_1\left(\frac{1+2-f_0}{7-4f_0} + \frac{3+6-f_0}{5+4f_0}\right),$$

$$1 + \frac{7}{12} \bar{J}_1(1/7) + \frac{5}{12} \bar{J}_1(3/5)\}$$

Pro Plan, 03.06.2015, § VL

Breitlinie von \overline{J}_0 und Reservenfunktion befest

$$\overline{J}_0(f_0) = \begin{cases} \frac{7+32f_0}{12}, & \text{for } f_0 \in [0, 3/8] \\ 15/12, & \text{ sonst} \end{cases}$$



$$\Rightarrow \pi_0^+(f_0) = \begin{cases} c, & f_0 \leq 3/8 \\ s, & f_0 > 3/8 \end{cases}$$